



Accélération de la résolution des équations de Goldstein par des méthodes d'apprentissage profond

Présenté par : Joel Pascal SOFFO WAMBO

Encadré par : Antoine BENSALAH

26 septembre 2022



université
PARIS-SACLAY
FACULTÉ
DES SCIENCES
D'ORSAY

AIRBUS

Table des matières

- 1 Introduction
 - La pollution sonore
 - Les équations de Goldstein
- 2 Cas d'intérêt dans le cadre du stage
 - Equation de transport en 1D
 - Equation de transport en 2D
 - Génération des données
 - Fonction de perte
- 3 Les opérateurs neuronaux
 - Architecture générale
 - Opérateur neuronal de Fourier (FNO)
 - Présentation du FNO
 - Résultats
 - Inconvénients
 - Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
 - Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO

1 Introduction

- La pollution sonore

- Les équations de Goldstein

2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D

- Equation de transport en 2D

- Génération des données

- Fonction de perte

3 Les opérateurs neuronaux

- Architecture générale

- Opérateur neuronal de Fourier (FNO)

- Présentation du FNO

- Résultats

- Inconvénients

- Réseau à noyau graphique (GNO)

- Présentation du GNO

- Résultats


- Opérateur neuronal informé de la physique (PINO)

- Les PINNs (*Physics-informed neural networks*)

- La méthode PINO

- Résultats

La pollution sonore



1 Introduction

- La pollution sonore
- **Les équations de Goldstein**

2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D
- Equation de transport en 2D
- Génération des données
- Fonction de perte

3 Les opérateurs neuronaux

- Architecture générale
- Opérateur neuronal de Fourier (FNO)
 - Présentation du FNO
 - Résultats
 - Inconvénients
- Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
- Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO
 - Résultats

Equation de Goldstein : 2D ($d = 2$)

Paramètres physiques

- Nombre d'onde : $k_0 > 0$ (pouvant $\in \mathbb{C}$)
- Mach de l'écoulement : $\mathbf{M}_0 : \mathbb{R}^d \rightarrow \mathbb{R}^d$ (simplifications : ρ_0, c_0 uniforme)
- source acoustique : $f : \mathbb{R}^d \rightarrow \mathbb{C}$.

Inconnues :

- Inconnue acoustique $\varphi : \Omega \rightarrow \mathbb{C}$
- Inconnue hydrodynamique : $\xi : \Omega \rightarrow \mathbb{C}^d$

Quantité d'intérêt pour Airbus : pression acoustique $p = -(-ik_0 + \mathbf{M}_0 \cdot \nabla)\varphi$.

Equations de Goldstein

Equations de Goldstein

$\varphi \in H^1(\Omega)$, $\xi \in H(\Omega, \mathbf{M}_0) := \{\zeta \in L^2(\Omega)^d / \mathbf{M}_0 \cdot \nabla \zeta \in L^2(\Omega)^d\}$ tels que :

$$\begin{cases} (-ik_0 + \mathbf{M}_0 \cdot \nabla)^2 \varphi - \Delta \varphi - \nabla \cdot \xi = f, & \text{sur } \Omega \\ (-ik_0 + \mathbf{M}_0 \cdot \nabla) \xi + (\xi \cdot \nabla) \mathbf{M}_0 + \omega_0 \times \nabla \varphi = \mathbf{0} & \text{sur } \Omega, \end{cases}$$

où ω_0 est la vorticité de l'écoulement : $\omega_0 := \nabla \times \mathbf{M}_0$,

Conditions aux bords

couche absorbante parfaitement adaptée donc $\varphi = 0$ sur $\partial\Omega$

$\xi = \mathbf{0}$ on $\partial\Omega^- := \{\mathbf{x} \in \partial\Omega / \mathbf{M}_0 \cdot \mathbf{n}(\mathbf{x}) < 0\}$

Représentation matricielle

Matrice d'opérateurs

Les équations de Goldstein peuvent s'écrire :

$$\begin{pmatrix} \mathcal{H}_{[k_0, \mathbf{M}_0]} & \mathcal{D} \\ \mathcal{V}_{[\mathbf{M}_0]} & \mathcal{T}_{[k_0, \mathbf{M}_0]} \end{pmatrix} \begin{pmatrix} \varphi \\ \xi \end{pmatrix} = \begin{pmatrix} f \\ \mathbf{0} \end{pmatrix}$$

- Opérateur d'Helmholtz convecté : $\mathcal{H}_{[k_0, \mathbf{M}_0]}(\varphi) := (-ik_0 + \mathbf{M}_0 \cdot \nabla)^2 \varphi - \Delta \varphi$
- Opérateur de transport : $\mathcal{T}_{[k_0, \mathbf{M}_0]}(\xi) := (-ik_0 + \mathbf{M}_0 \cdot \nabla)\xi + (\xi \cdot \nabla)\mathbf{M}_0$
- Opérateurs de couplage $\mathcal{D}(\xi) := -\nabla \cdot \xi$ et $\mathcal{V}_{[\mathbf{M}_0]}(\varphi) := \omega_0 \times \nabla \varphi = (\nabla \times \mathbf{M}_0) \times \nabla \varphi$

Difficultés : $\mathcal{T}_{[k_0, \mathbf{M}_0]}^{-1}$ est très coûteux

- ξ est une inconnue vectorielle,
- $\mathcal{T}_{[k_0, \mathbf{M}_0]}^{-1}$ demande une discrétisation beaucoup plus fine que $\mathcal{H}_{[k_0, \mathbf{M}_0]}$

1 Introduction

- La pollution sonore
- Les équations de Goldstein

2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D
- Equation de transport en 2D
- Génération des données
- Fonction de perte

3 Les opérateurs neuronaux

- Architecture générale
- Opérateur neuronal de Fourier (FNO)
 - Présentation du FNO
 - Résultats
 - Inconvénients
- Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
- Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO
 - Résultats

Equation de transport 1D

Equation de transport 1D

$$\begin{cases} -ik_0\psi(x) + m_0(x)\psi'(x) = g(x), & \text{for } x \in [0, 1], \\ \psi(0) = 0 \end{cases}$$

avec : $m_0 : [0, 1] \rightarrow \mathbb{R}_+^*$.

La solution analytique s'écrit :

$$\psi(x) = \mathcal{T}_{[k_0, m_0]}^{-1} g(x) = \int_0^x \exp\left(\int_s^x i \frac{k_0}{m_0(\tau)} d\tau\right) \frac{g(s)}{m_0(s)} ds$$

Remarque : Nous nous sommes tout d'abord intéressé au cas 1D où m_0 est constant, mais les observations étant exactement les mêmes que dans le cas non constant, nous sauterons cette partie.

1 Introduction

- La pollution sonore
- Les équations de Goldstein

2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D
- **Equation de transport en 2D**
- Génération des données
- Fonction de perte

3 Les opérateurs neuronaux

- Architecture générale
- Opérateur neuronal de Fourier (FNO)
 - Présentation du FNO
 - Résultats
 - Inconvénients
- Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
- Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO
 - Résultats

Equation de transport 2D

Equation de transport 2D

$$\begin{cases} \mathbf{M}_0 \cdot \nabla \psi - ik_0 \psi = g \frac{d\mathbf{M}_0}{dy}, & \text{in } \Omega, \end{cases} \quad (1a)$$

$$\begin{cases} \psi = 0, & \text{on } \partial\Omega^- \end{cases} \quad (1b)$$

Pour simplifier l'équation, on se place dans le cadre suivant :

Ecoulement cisailé : $\mathbf{M}_0(x, y) := M_0(y)\mathbf{e}_x$,

Equation de transport 2D

On obtient donc l'équation suivante :

Equation de transport 2D

$$\begin{cases} M_0(y) \partial_x \psi(x, y) - ik_0 \psi(x, y) = g(x, y) M'_0(y), & (x, y) \in]x_1, x_2[\times]y_1, y_2[, \\ \psi(x_1, y) = 0, & \forall y \in]y_1, y_2[, \end{cases}$$

La solution analytique s'écrit :

Inverse de l'opérateur de transport

$$\psi(x, y) = \left(\mathcal{T}_{[k_0, M_0]}^{-1} g \right) (x, y) = \frac{M'_0(y)}{M_0(y)} \int_{x_1}^x e^{\frac{ik_0}{M_0(y)}(x-s)} g(s) ds.$$

1 Introduction

- La pollution sonore
- Les équations de Goldstein

2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D
- Equation de transport en 2D
- Génération des données
- Fonction de perte

3 Les opérateurs neuronaux

- Architecture générale
- Opérateur neuronal de Fourier (FNO)
 - Présentation du FNO
 - Résultats
 - Inconvénients
- Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
- Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO
 - Résultats

Données d'entrée et de sortie

On discrétise le domaine Ω en K points pour pouvoir créer une base de données.
Soit $\Gamma = \{x_1, x_2, \dots, x_K\}$ les points de discrétisation.

Données d'entrée

- Mach de l'écoulement $m : m|_{\Gamma} \in \mathbb{R}^K$
- La source $g : g|_{\Gamma} \in \mathbb{C}^K$ (ou $\mathbb{R}^{K \times 2}$)
- Les points de discrétisation

Données de sortie

- La solution $\psi : \psi|_{\Gamma}$

Cas 1D : Génération des données

Loi $\mathcal{P}_L$

Soit $\mathcal{P}_L$ une loi telle que :

$$a \sim \mathcal{P}_L([a_{min}, a_{max}]) \Leftrightarrow a = \sum_{l=1}^L \alpha_l T_l, \quad \alpha_1, \dots, \alpha_n \stackrel{i.i.d}{\sim} \mathcal{U}([0, 1])$$

où les T_l sont des polynômes de Chebyshev normalisés tels que $a \in [a_{min}, a_{max}]$

L'écoulement m

$$m \sim \mathcal{P}_{10}(m_{range})$$

La source g

$$g(x_k) = e^{i\alpha(x_k)x_k} \left(a + e^{\frac{-(x-x_m)^2}{2\sigma^2}} \right)$$

avec : $\alpha \sim \mathcal{P}_{10}(\alpha_{range})$, $a \sim \mathcal{P}_{10}([-1, 1])$, $k = 1, \dots, K$

La solution ψ

$(\psi(x_k))_{1 \leq k \leq K}$ générées à partir d'un *solver* s'appuyant sur la solution analytique

Cas 1D : Génération des données

On considère les bases de données suivantes :

- Base de données **db1**

- Nombre de points du maillage (discrétisation spatiale) : $K = 512$
- Intervalle de valeurs de m : $m \in m_{range} = [0.4, 0.5]$
- Intervalle de valeurs de α : $\alpha \in \alpha_{range} = [40, 50]$
- $k_0 = 90$

- Base de données **db2**

- Nombre de points du maillage (discrétisation spatiale) : $K = 512$
- Intervalle de valeurs de m : $m \in m_{range} = [0.2, 0.7]$
- Intervalle de valeurs de α : $\alpha \in \alpha_{range} = [25, 150]$
- $k_0 = 90$

Figures : Cas 1D




Figure – Observations 1D (db2)

Cas 2D : Génération des données

L'écoulement m

$$m(y_k) = m1 + (m2 - m1)e^{-\frac{y_k - y_m}{2\sigma^2}}$$

avec $m1 \sim \mathcal{P}_{10}(m_{range1})$, $m2 \sim \mathcal{P}_{10}(m_{range2})$, $\sigma \sim \mathcal{P}_{10}(\sigma_{range})$

La source g

$$g(x_k, y_k) = a(x_k)e^{i\alpha_x(x_k)x_k}e^{i\alpha_y(y_k)y_k}$$

avec $a \sim \mathcal{P}_{10}(a_{range})$, $\alpha_x \in \mathcal{P}_{10}(\alpha_{xrange})$, $\alpha_y \in \mathcal{P}_{10}(\alpha_{yrange})$, $(x_k, y_k) \in \Gamma \times \Gamma$

La solution ψ

$(\psi(x_k, y_k))_{1 \leq k \leq K}$ générées à partir d'un *solver* s'appuyant sur la solution analytique.


Cas 2D : Génération des données

On considère la base de données suivante :

Base de données **db3** :

- Nombre de points du maillage (discrétisation spatiale) : $K = 256 \times 256$
- Intervalle de valeurs de $m1$: $m1 \in m_{range1} = [0.2, 0.3]$
- Intervalle de valeurs de $m2$: $m2 \in m_{range2} = [0.4, 0.5]$
- Intervalle de valeurs de σ : $\sigma \in \sigma_{range} = [0.02, 0.2]$
- $y_m = 0.1$
- Intervalle de valeurs de a : $a \in a_{range} = [1, 5]$
- Intervalle de valeurs de α_x : $\alpha_x \in \alpha_{xrange} = [1, 20]$
- Intervalle de valeurs de α_y : $\alpha_y \in \alpha_{yrange} = [1, 20]$
- $k_0 = 10$

Figures : Cas 2D



Observations 2D (db3)

1 Introduction

- La pollution sonore
- Les équations de Goldstein

2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D
- Equation de transport en 2D
- Génération des données
- **Fonction de perte**

3 Les opérateurs neuronaux

- Architecture générale
- Opérateur neuronal de Fourier (FNO)
 - Présentation du FNO
 - Résultats
 - Inconvénients
- Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
- Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO
 - Résultats

Fonction de perte

Soit ψ et ψ' deux fonctions complexes qu'on discrétise sur Γ

$$\psi|_{\Gamma} = (\psi_k)_{1 \leq k \leq K}$$

$$\psi'|_{\Gamma} = (\psi'_k)_{1 \leq k \leq K}$$

Fonction de perte L2 relative

$$\begin{aligned} loss_{data}(\psi, \psi') &= \frac{\|\psi - \psi'\|_{L^2(\Gamma)}}{\|\psi\|_{L^2(\Gamma)}} \\ &= \sqrt{\frac{\sum_{k=1}^K |\operatorname{Re}(\psi_k) - \operatorname{Re}(\psi'_k)|^2 + |\operatorname{Im}(\psi_k) - \operatorname{Im}(\psi'_k)|^2}{\sum_{k=1}^K |\operatorname{Re}(\psi_k)|^2 + |\operatorname{Im}(\psi_k)|^2}} \end{aligned}$$

1 Introduction

- La pollution sonore
- Les équations de Goldstein

2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D
- Equation de transport en 2D
- Génération des données
- Fonction de perte

3 Les opérateurs neuronaux

- **Architecture générale**
- Opérateur neuronal de Fourier (FNO)
 - Présentation du FNO
 - Résultats
 - Inconvénients
- Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
- Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO
 - Résultats

Intuition

Ecriture de la solution ψ en 1D

$$\begin{aligned}\psi(x) &= \mathcal{T}_{[k_0, m_0]}^{-1} g(x) \\ &= \int_0^x \exp\left(\int_s^x i \frac{k_0}{m_0(\tau)} d\tau\right) \frac{g(s)}{m_0(s)} ds \\ &= \int_D G(x, s) g(s) ds\end{aligned}$$

avec : $G(x, s) = 1_{x-s \geq 0} \exp\left(\int_s^x i \frac{k_0}{m_0(\tau)} d\tau\right) \frac{1}{m_0(s)}$, $D = [0, 1]$.

Théorème de l'approximation universelle

G continue $\implies G \approx \kappa_\phi$, où κ_ϕ est un réseau de neurones.

Architecture itérative [2]

$$\begin{aligned}v_{t+1}(x) &= \sigma[Wv_t(x) + \int_D \kappa_\phi(x, s, m(x), m(s))v_t(s)\nu_x(ds)] \\ &= \sigma(Wv_t(x) + \mathcal{K}(m; \phi)v_t(x))\end{aligned}$$

avec :

- $t = 0, \dots, T - 1$, T le nombre de couches,
- $v_i(x) \in \mathbb{R}^{d_v}$,
- $W \in \mathbb{R}^{d_v}$ un vecteur de poids
- $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ une non-linéarité,
- $\kappa_\phi : \mathbb{R}^{2(d+1)} \rightarrow \mathbb{R}^{d_v \times d_v}$ un réseau de neurones où ϕ représente l'ensemble des paramètres du réseau,
- $\mathcal{K}(m; \phi)v_t(x) = \int_D \kappa_\phi(m(x), m(y), x, y)v_t(y)dy$ (Opérateur intégral).

1 Introduction

- La pollution sonore
- Les équations de Goldstein

2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D
- Equation de transport en 2D
- Génération des données
- Fonction de perte

3 Les opérateurs neuronaux

- Architecture générale
- **Opérateur neuronal de Fourier (FNO)**
 - Présentation du FNO
 - Résultats
 - Inconvénients
- Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
- Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO
 - Résultats

Intuitions du FNO tirées de [1]

Suppositions sur κ_ϕ

- κ_ϕ ne dépend pas de m ,
- $\kappa_\phi(x, y) = \kappa_\phi(x - y)$.

Réécriture de l'opérateur intégral

$$\begin{aligned}\mathcal{K}(\phi)v_t(x) &= \int_D \kappa_\phi(x, y)v_t(y)dy \\ &= \int_D \kappa_\phi(x - y)v_t(y)dy \\ &= \kappa_\phi \star v_t(x). \\ &= \mathcal{F}^{-1}(\mathcal{F}(\kappa_\phi) \cdot \mathcal{F}(v_t))(x)\end{aligned}$$

En pratique

- On utilise la Transformée de Fourier Discrète (TFD),
- On ne conserve que les k_{max} premiers modes.


$$(\mathcal{F}(\kappa_\phi) \cdot \mathcal{F}(v_t))_{i,j} = \sum_{k=1}^{d_v} \mathcal{F}(\kappa_\phi)_{i,j,k} \cdot \mathcal{F}(v_t)_{i,k}$$

avec $i = 1, \dots, k_{max}$ et $j = 1, \dots, d_v$

$$\mathcal{F}(\kappa_\phi) \in \mathbb{C}^{k_{max} \times d_v \times d_v}$$

$$\mathcal{F}(v_t) \in \mathbb{C}^{k_{max} \times d_v}$$

Architecture du FNO





Architecture générale de l'opérateur neuronal de Fourier tirée de [1]

Résultats FNO 1D

Résultats FNO 1D

Modèles	Données train	Données test	loss_train	loss_test
FNO 1D (db1)	$n_{train} = 10.000$	$n_{test} = 2000$	0.00467	0.00702
FNO 1D (db2)	$n_{train} = 10.000$	$n_{test} = 2000$	0.01251	0.54834



Résultats FNO 2D

Résultats FNO 2D				
Modèle	Données train	Données test	loss_train	loss_test
FNO 2D	$n_{train} = 3000$	$n_{test} = 100$	0.019	0.03




Figure – Résultats FNO 2D

Inconvénients du FNO

- Nécessité d'une discrétisation uniforme due à l'utilisation de la FFT,
- Besoin de beaucoup de données pour apprendre l'opérateur.

1 Introduction

- La pollution sonore
- Les équations de Goldstein

2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D
- Equation de transport en 2D
- Génération des données
- Fonction de perte

3 Les opérateurs neuronaux

- Architecture générale
- Opérateur neuronal de Fourier (FNO)
 - Présentation du FNO
 - Résultats
 - Inconvénients
- Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
- Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO
 - Résultats

Présentation du GNO [2]

Reconsidérons l'architecture itérative :

$$v_{t+1}(x) = \sigma(Wv_t(x) + \int_D \kappa_\phi(x, s, m(x), m(s))v_t(s)\nu_x(ds)) \quad t = 0, \dots, T-1,$$

- On pose $\nu_x(ds) = 1_{B(x,r)}ds$
- On approche l'intégrale par Monte Carlo

On obtient l'écriture suivante :

Formule générale du GNO


$$v_{t+1}(x) = \sigma(Wv_t(x) + \frac{1}{\text{card}(N(x))} \sum_{y \in N(x)} \kappa(e(x, y))v_t(y)),$$

Présentation GNO [2]

- $N(x)$ l'ensemble des voisins de x ,
- $W \in \mathbb{R}^{n \times n}$,
- $e(x, y) = (x, y, m(x), m(y))$ appelé *edges features*,
- $\kappa(e(x, y))$ un réseau de neurones prenant $e(x, y)$ en entrée et en sortie une matrice de taille $d_v \times d_v$.

Graph neural network

- kernel = Matrice d'adjacence
- Intégration = Message passing



Résultats

Résultats GNO 1D				
Modèle	Données train	Données test	loss_train	loss_test
GNO 1D (db1)	$n_{train} = 100$	$n_{test} = 10$	0.61	0.65
GNO 1D (db2)	$n_{train} = 100$	$n_{test} = 10$	0.7	0.85

Explication des résultats

- $G(x, s) = 1_{x-s \geq 0} \exp \left(\int_s^x i \frac{k_0}{m_0(\tau)} d\tau \right) \frac{1}{m_0(s)}$
Dépendance de κ_ϕ en tous les points entre x et s ,
- Paramétrisation de κ_ϕ dans $\mathbb{R}$, hors G est à valeurs complexes.

1 Introduction

- La pollution sonore
- Les équations de Goldstein


2 Cas d'intérêt dans le cadre du stage

- Equation de transport en 1D
- Equation de transport en 2D
- Génération des données
- Fonction de perte

3 Les opérateurs neuronaux

- Architecture générale
- Opérateur neuronal de Fourier (FNO)
 - Présentation du FNO
 - Résultats
 - Inconvénients
- Réseau à noyau graphique (GNO)
 - Présentation du GNO
 - Résultats
- Opérateur neuronal informé de la physique (PINO)
 - Les PINNs (*Physics-informed neural networks*)
 - La méthode PINO
 - Résultats

Les PINNs (*Physics-informed neural networks*)[4]



Les PINNs (*Physics-informed neural networks*)[4]

Considérons l'équation de transport 1D :

$$\begin{cases} -ik_0\psi(x) + m_0(x)\psi'(x) = g(x), & \text{pour } x \in [0, 1], \\ \psi(0) = 0, \end{cases}$$

avec : $m_0 : [0, 1] \rightarrow \mathbb{R}_+^*$.

La fonction de perte à optimiser est :

$$loss_{total} = loss_{NN} + loss_{pde}.$$

avec :

- $loss_{NN} = \|\psi - \psi_{pred}\|_{\Gamma}$ où ψ_{pred} est la solution prédite par le réseau de neurones.
- $loss_{pde} = \|ik_0\psi_{pred} + m\psi'_{pred} - g\|_{\Gamma} + |\psi_{pred}(0)|.$

La méthode PINO

- Combinaison entre les PINNs et les opérateurs neuronaux (On s'intéresse ici au cas du FNO),
- Remplacement du réseau de neurones des PINNs par celui du FNO.

La méthode PINO [3]

Etapes du PINO

- **Phase d'entraînement** : apprentissage de l'opérateur G_θ en utilisant les fonctions de perte $loss_{data}$ et $loss_{pde}$. La fonction de perte à minimiser ici s'écrit :

$$loss_{total} = \alpha loss_{data}(\psi, G_\theta(a)) + \beta loss_{pde}(G_\theta(a), a),$$

avec $\alpha, \beta > 0$ et a l'ensemble des données d'entrée.

On utilise ici la norme L2 relative pour calculer $loss_{pde}$.

En 1D par exemple, on a :

$$\begin{aligned} loss_{pde}(G_\theta(a), a) &= loss_{pde}(\psi_{pred}, a) \\ &= \|ik_0\psi_{pred} + m(x)\psi'_{pred}(x) - g(x)\|_{L^2(\Gamma)} + |\psi_{pred}(0)| \end{aligned}$$

- **Phase d'optimisation (optionnelle)** : approximation de la solution pour une instance de l'EDP à partir l'opérateur G_θ précédemment appris, en utilisant la fonction de perte $loss_{pde}$.

Résumé de de la phase d'entrainement

[1] Initialisation de G_θ

- Entrées : $a = \{a_j\}_{j=1}^{batch} = \{x, m_j, Re(g)_j, Im(g)_j\}_{j=1}^{batch}$
- Calcul de $loss_{total} = \alpha loss_{data}(\psi, G_\theta(a)) + \beta loss_{pde}(G_\theta(a), a)$
- Optimisation de G_θ par rétropropagation
- Génération de nouveaux paramètres (hors base d'apprentissage) $a' = \{a'_j\}_{j=1}^{batch}$
- Calcul de $loss_{pde}(G_\theta(a'), a')$
- Calcul de $loss_{data}$ en utilisant les instances a
- $loss_{total} = \alpha loss_{data}(\psi, G_\theta(a)) + \beta loss_{pde}(G_\theta(a'), a')$
- Optimisation de G_θ par rétropropagation

Résultats

Résultats PINO 1D

Modèle	Données	Instances	loss_train	loss_test
FNO 1D (db1)	$n_{train} = 3000, n_{test} = 2000$	0	0.0117	0.42
PINO 1D (db1)	$n_{train} = 3000, n_{test} = 2000$	100K	0.05	0.076
FNO 1D (db2)	$n_{train} = 10000, n_{test} = 2000$	0	0.02	0.51
PINO 1D (db2)	$n_{train} = 10000, n_{test} = 2000$	200K	0.018	0.38

Résultats PINO 2D

Modèle	Données	Instances	loss_train	loss_test
FNO 2D (db3)	$n_{train} = 100, n_{test} = 10$	0	0.02	0.65
PINO 2D (db3)	$n_{train} = 100, n_{test} = 10$	1K	0.05	0.6

Synthèse et futurs travaux

- L'opérateur neuronal (FNO) de Fourier donne de bons résultats mais présente quelques contraintes,
- Le réseau à noyau graphique (GNO) nécessite une étude plus poussée dans notre cas,
- La méthode PINO est une bonne alternative pour le besoin de données du FNO mais semble moins performer quand l'équation se complique (Cas 2D),
- Implémenter des méthodes permettant de prendre en compte des discrétisations non uniformes,
- Monter en complexité au fur et à mesure afin d'arriver au final à l'opérateur de "transport Goldstein" présenté au tout début
$$(\mathcal{T}_{[k_0, \mathbf{M}_0]}(\xi) := (-ik_0 + \mathbf{M}_0 \cdot \nabla)\xi + (\xi \cdot \nabla)\mathbf{M}_0).$$

Bibliographie I

- [1] Zongyi LI et al. “Fourier Neural Operator for Parametric Partial Differential Equations”. In : *CoRR* abs/2010.08895 (2020). arXiv : 2010.08895. URL : <https://arxiv.org/abs/2010.08895>.
- [2] Zongyi LI et al. “Neural Operator : Graph Kernel Network for Partial Differential Equations”. In : *CoRR* abs/2003.03485 (2020). arXiv : 2003.03485. URL : <https://arxiv.org/abs/2003.03485>.
- [3] Zongyi LI et al. “Physics-Informed Neural Operator for Learning Partial Differential Equations”. In : *CoRR* abs/2111.03794 (2021). arXiv : 2111.03794. URL : <https://arxiv.org/abs/2111.03794>.

Bibliographie II

- [4] M. RAISSI, P. PERDIKARIS et G.E. KARNIADAKIS. “Physics-informed neural networks : A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. In : *Journal of Computational Physics* 378 (2019), p. 686-707. ISSN : 0021-9991. DOI : <https://doi.org/10.1016/j.jcp.2018.10.045>. URL : <https://www.sciencedirect.com/science/article/pii/S0021999118307125>.

MERCI DE VOTRE ATTENTION !

